

QCon
全球软件开发大会

From Computer Use to Datacenter Use for AI

演讲者

谈鉴锋 蚂蚁集团操作系统研发经理

周天昱 蚂蚁集团高级开发工程师

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

- 01 引言：AI 开发者被基础设施"劝退"
- 02 AKernel 架构：Monorepo + AI 辅助的工程实践
- 03 开发者体验：像调用本地函数一样使用数据中心
- 04 一站式部署：一键从零到多云
- 05 Agent 时代三大技术支柱
- 06 实践验证与总结展望

01 引言

AI 开发者正在被基础设施"劝退"



模型能力日趋强大

大模型推理与 Agent 能力持续突破


Computer Use 已经实现

Datacenter Use 才是 AI 基础设施的终局

开发者体验严重滞后

依赖冲突、部署复杂、运维繁重

团队间重复造轮子




基础设施使用门槛居高不下

从资源接入、调度器、网络配置到监控体系——无论个人还是企业，都不可避免陷入 "Build Your Own Cluster" 泥潭

AI 原生基础设施的三大挑战

AKernel 的回答



02 AKernel 架构

Monorepo + AI-powered


AKernel Develop

统一代码库 (Monorepo) + 14 个 Git Submodule


从沙箱运行时、资源管理、网络到 SDK 与调度，全栈组件集中管理
通过 submodule 锁定外部依赖版本，消除分布式多仓库的版本矩阵爆炸问题

AI 辅助开发: ≤ 3 人全栈团队

80% 代码由 AI 辅助生成，覆盖 Go/Rust/Python/C++ 多语言栈
无传统的需求/研发/测试/运维分工，一人端到端负责，打破"基础设施必须大团队"的固有认知



AKernel on Public Cloud



03 开发者体验

像调用本地函数一样使用数据中心


Sandbox/FaaS/Spark/...

Sandbox SDK

```
from akernel_sdk import Sandbox

with Sandbox(cpu=2000, memory=4096) as sb:
    sb.commands.run("python train.py")
```







- 自定义镜像
- checkpoint/restore
- 双向代理（本地 to sandbox, sandbox to 本地）
- 多种可选的 sandbox 运行时（gvisor, firecracker 等）




基于开源标准方案的监控体系 (metric/log/trace)

实时资源监控

Per-node snapshot ⓘ

host_name ⓘ	CPU usage % ↓ ⓘ	CPU limit (cores) ⓘ	Memory usage % ⓘ	Memory total ⓘ	/ usage % ⓘ	/ capacity ⓘ
akernel-0-0060020	 36.4%	48.00	 0.6%	1.11 TiB	 2.8%	400 GiB
akernel-0-0060022	 36.3%	64.00	 0.5%	1.97 TiB	 5.6%	400 GiB
akernel-0-0060021	 35.3%	48.00	 0.8%	1.11 TiB	 2.5%	400 GiB

Sandbox 创建链路 trace



04 一站式部署

Terraform 一键从零到多云

一站式部署: Terraform + Helm, 10 分钟就绪

多云 Terraform 模块化部署

已支持阿里云 ACK 与华为云 CCE

仓库内置 Skill, claude code 自动部署

Helm 自动编排核心组件

所有集群组件 Helm Chart 一键部署

极简运维闭环

ak CLI: list / delete / exec / ...

Grafana 仪表盘与日志自动生成, 开箱即用

Fresh Apply (23:18:27 → 23:27:06, 8m39s)

阶段	耗时
Data sources	~1s
VPC	6s
vSwitch	14s
ACK 集群创建	4m16s (256s)
Node pool	88s
Namespace + StorageClass	2s
Helm 部署	149s (2m29s)

04

三大技术支柱

Agent 时代的核心基础设施能力

openYuanrong 分布式调度与数据系统

1

核心运行时 (C++/Python/Go) + 函数系统 + 数据系统, 协同构成完整分布式执行引擎

2

数据系统提供高性能分布式缓存, 支持跨节点、跨资源类型的高效数据流动

3

RL 训练数据高效流通
Agent 多实例间状态共享
Spark 分布式计算

● 极致冷启动：AFaaS 安全沙箱 (OSDI'25)



性能指标

10ms 节点侧冷启动, 40ms 端到端延迟
相较传统容器方案 (秒级启动) 提升 2 个数量级



技术实现

nanovisor (gVisor) fork
distill-fs (Rust FUSE) 镜像按需懒加载
Dragonfly P2P 加速镜像分发




核心应用场景

Agent Sandbox 高并发冷启动 (蒸馏、RL、评测、Serving)

状态持久化: Checkpoint / Restore 全链路支持

- SDK、调度器到节点端全栈实现，完整覆盖 Agent 生命周期的状态快照与恢复链路
- Agent 长期待机时挂起释放资源，唤醒后从断点继续
- 应用于多 Agent 长会话状态迁移，带状态的快速启动



06

实践验证与总结


从真实场景到未来演进

典型场景


Agentic RL 全链路（蒸馏、RL、评测）

Serverless Function

Spark 大数据处理



● 总结: AKernel 核心价值与展望



可持续的工程范式

Monorepo + ≤ 3 人团队 + 80% AI 辅助, 覆盖 Go/Rust/Python/C++ 多语言栈, 为中小团队提供可借鉴路径

Agent friendly

端到端 40ms 冷启动
Checkpoint/Restore
Sandbox API 开箱即用

一键部署, 随处运行

基于 Terraform 的多云部署 (阿里云 ACK + 华为云 CCE) + Helm Chart 一键编排, 10 分钟从零到可用集群

未来演进方向

XPU 支持
Win/macOS/Android sandbox

THANKS

让 AI 开发者专注于模型与应用，而非基础设施

AKernel — From Computer Use to Datacenter
Use



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

