

QCon
全球软件开发大会

蚂蚁阿福 Agent: 医疗研发范式与实践

郭晓

蚂蚁集团 医疗工程引擎



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01

蚂蚁阿福 Agent 的痛点、挑战

02

Agent 研发范式的北极星指标与技术体系

03

Agent 上下文的挑战

04

从 RAG 到 Agentic RAG 的实战

05

医疗记忆

06

训推优化

01

蚂蚁阿福Agent的痛点与挑战



医疗 Agent 的核心挑战

专业性要求极高

医疗领域错误容忍度极低，一个错误回答可能影响患者健康决策
需要严格遵循循证医学原则

非确定性挑战

大模型复读机、数值计算错误、异常处理

长期记忆缺失

每位患者的健康状况、病史、用药记录各不相同
需要精准的个性化健康档案支撑

风控合规

患者隐私保护、数据安全合规要求严格
防蒸馏攻击、风险防控不可或缺



Agent 研发范式与传统研发范式的区别

传统业务研发

迭代频率：双周

- 需求→设计→开发→测试→上线
- 代码驱动，人工 QA 验证
- 变更周期长，迭代速度受限
- 适合确定性需求场景

搜推研发范式

迭代频率：周 1~2 次

- 数据驱动，A/B Test 验证
- 特征工程 + 模型训练
- 线上指标牵引优化方向
- 适合效果可量化的场景


Agent 研发范式

迭代频率：天级别

- 评测驱动 (EBDD)，Benchmark 牵引
- Prompt + RAG + 模型+工具 协同迭代
- Badcase 驱动的快速闭环
- harness AI 人均提效 30%~10x

Agent 研发范式北极星指标 与技术体系

整体技术架构





评测体系的建设 EBDD

Evaluation And Badcase Driven Development

以评测为核心驱动力的研发范式，通过系统化的 Benchmark 建设和 Badcase 分析，实现从「代码驱动」到「评测驱动」的范式转变，建立可量化、可追踪、可闭环的研发流程。

E - Evaluation Benchmark 评测体系

- 基于 Rubric 的评测方式
- 多正确答案场景覆盖
- 自动化评测 + 人工终审
- 70% 场景覆盖，X 万评测集
- 评测耗时从 1-2 天降至小时级

B - Badcase 体验优化

- 多种反馈渠道
- 动态分拣
- 核对与巡检

D - Driven 流水线

- 评测→定位→修复→验证闭环
- 快速迭代，自动发现天级别交付

D - Development 生产化

- 评测能力线上化
- A/B 实验与灰度验证
- 监控告警与持续优化

评测和 Badcase 驱动的研发范式

Benchmark + Badcase 双循环驱动



持续循环迭代，不断提升模型与系统能力

小时级

评测耗时
(原 1-2 天)

评测可靠性

可靠评测 = 稳定数据集 + 足够样本量 + 可信评审者

数据集是否稳定

评测集二义性，以及是否有区分度

判断

区间越宽，数据越不稳。

样本量够不够

先定义最小有效提升，再谈样本量。

判断

想看更小提升，成本会陡增。

裁判靠不靠谱

多次打分不一致，是有效提升，还是裁判波动。

判断

多次一致性(变异系数)

03

Agent上下文挑战



医疗上下文的挑战

上下文工程

01

信息密度高

医疗对话涉及症状描述、检查结果、用药记录、既往病史等多维信息，单次会话信息量远超一般对话场景

02

多轮对话依赖

医疗问诊天然是多轮交互过程，需要精确追踪上下文中的关键实体（药品、症状、指标）并保持语义一致性

03

上下文窗口有限

复杂病例可能涉及数十轮对话和大量参考资料，超出模型上下文窗口限制，需要高效的压缩与检索策略

04

跨 Agent 共享

主子 Agent 架构下，上下文在不同 Agent 间传递时容易出现信息损失或污染，需要设计合理的共享与隔离机制



长上下文的处理

上下文工程

关键信息抽取

- 有限抽取策略：识别并保留诊断关键信息（主诉、症状、检查结果）
- 人工确认机制：关键医疗信息需患者确认，避免误抽取
- 结构化存储：将非结构化对话转为结构化健康档案

上下文压缩

- 语义压缩：保留核心语义，去除冗余信息
- 选择性传递：根据当前任务动态选择相关上下文片段
- 渐进式摘要：长对话自动生成分段摘要

分层记忆机制

- 短期记忆：当前会话内的即时上下文管理
- 长期记忆：跨会话的患者健康档案与历史记录
- 记忆融合：短期与长期记忆的动态检索与融合



主子 Agent 的上下文共享

上下文工程

问题与技术挑战

- 上下文有限：单 Agent 无法承载复杂医疗推理的全部上下文
- 上下文污染：不同子任务的上下文混合导致推理质量下降
- 长上下文指令遵循：超长上下文下模型对指令的遵循度下降

技术方案：单 Agent → 多 Agent 架构升级

- 主 Agent 负责任务分解与上下文调度
- 子 Agent 专注特定领域（检索、诊断、用药推荐等）
- 上下文路由：根据子任务类型选择性传递相关上下文
- 结果聚合：子 Agent 结果经主 Agent 融合后生成最终回答

业务成果：深度检索准确率 提升 19%

04

从 RAG 到 Agentic RAG 的实战

从 RAG 到 Agent RAG 的实战


检索增强生成

技术挑战

- 医疗检索效果要求极高：药品类问题强依赖检索
- 医保类问题强依赖检索，且政策具有区域性和时效性
- 多跳 Query 处理：如「肝功能不好+发烧→能吃什么药→怎么吃」

技术方案

- Index 策略 + 混合检索：结合稠密检索与稀疏检索
- 融合医学专业性的 Agentic 检索框架
- 问题合成：选稀有实体、模糊化、模型生成合成思路
- 高质量轨迹合成：强模型生成轨迹、思维链重写



AQ 问答准确率

业界对抗第一



Agentic RAG 的架构与医疗询证检索

Agent 框架 + 循证医学检索

将循证医学（Evidence-Based Medicine）思想融入 Agent 检索框架，通过多阶段检索策略实现高精度医疗问答。

Stage 1: Query 理解

- 意图识别与实体抽取
- 多跳问题分解
- 检索策略路由

Stage 2: 循证检索

- 权威指南文献检索
- 药品说明书精确匹配
- 医保政策区域化检索

Stage 3: 证据融合

- 多源证据排序与去重
- 证据等级评估
- 结合推理生成回答

检索 Benchmark BRIGHT 取得 SOTA | 框架已开源 | 发表论文一篇

05 记忆



医疗记忆的挑战与难点

从数据、记忆、决策到治理，医疗个性化的难点贯穿全链路

1 用户数据管理复杂

- 长期信息与短期状态混杂
- 健康状态持续变化，信息容易过期
- 多轮对话中上下文容易漂移

2 数据融合与理解难度高

- 数据来源多且格式不统一
- 数据质量参差不齐
- 信息冲突难以消解


3 个性化决策与安全控制难平衡

- 何时调用个性化不易判断
- 高风险信息不能漏也不能乱用
- 个性化越强，错误代价越高

4 效果评估与合规治理门槛高

- 效果难评估
- 结果需要可解释、可追溯
- 隐私与合规要求高

记忆架构方案



06 训推优化

推理优化

推理加速

TTFT (Time To First Token)

- Prompt 缓存: 复用高频 Prompt 的 KV Cache
- Prefill 优化: 分离 Prefill 与 Decode 阶段
- 模型量化: FP8/INT8 降低计算开销
- 业务隔离: 长短分离

TPOT (Time Per Output Token)

- Continuous Batching: 动态批处理请求
- Speculative Decoding: 小模型预测+大模型验证
- Speculative Decoding: 长短分离

Agent RL 性能优化方案

推理加速

Agent RL 训练架构挑战

- Agent 运行环境与训练耦合严重，工具 Env 与训练环境不分离
- 训练耗时长：1T 模型，单 step 43 分钟
- Rollout 1200s | Reward 600s | Reshard 800s
- 模型 Reward 达不到要求，需要升级 Reward 架构

优化方案

升级 Agent 训练架构

解耦运行环境与训练环境

FP8 量化加速

Rollout 阶段从 1200s 降至 1080s

半异步化训练


进一步降至 960s，减少等待开销

Reward Service 升级

Reward 计算从 600s 降至 120s

社区代码优化

Reshard 从 800s 降至 48s



全球首个支持开源FP8训推方案

全球首个支持开源QAT训练方案

THANKS

AI Agent 正在重新定义医疗
健康

AI Agent Is Redefining Healthcare



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

